



Performance Analyse der Optimierung von Datenbankabfragen in der HANA Calculation Engine

Projektarbeit 2

im Rahmen der Prüfung zum
Bachelor of Science (B.Sc.)

des Studienganges Wirtschaftsinformatik
an der Dualen Hochschule Baden-Württemberg Mannheim

von

Jared Heinrich

Abgabedatum:	26. August 2024
Bearbeitungszeitraum:	06.05.2024 - 25.08.2024
Matrikelnummer, Kurs:	5101479, WWI22SEA
Ausbildungsfirma:	SAP SE Dietmar-Hopp-Allee 16 69190 Walldorf, Deutschland
Unternehmensbetreuer:	Rainer Agelek
Wissenschaftlicher Betreuer:	Prof. Dr. Hans-Henning Pagnia

Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Thema:

*Performance Analyse der Optimierung von Datenbankabfragen in der HANA
Calculation Engine*

selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Mannheim, den 14. Juni 2024

Heinrich, Jared

Inhaltsverzeichnis

Abkürzungsverzeichnis	III
Abbildungsverzeichnis	IV
Tabellenverzeichnis	V
Quellcodeverzeichnis	VI
1 Einleitung	1
2 Grundlagen	2
2.1 Calculation Engine	2
2.2 Ausführung von Datenbankabfragen	2
2.3 Verschiedene Arten von Performance Analyse	2
3 Aktueller Stand der Performance Analyse in der Calculation Engine	3
3.1 Google Benchmark	3
3.2 HANA Profiler	4
4 Benchmarking-Konzept	7
4.1 Messung	7
4.2 Testdaten	7
5 Umsetzung	8
5.1 Implementation der neuen Methode	8
6 Verifikation	9
7 Fazit und Ausblick	10
Literaturverzeichnis	VII

Abkürzungsverzeichnis

CE Calculation Engine

Abbildungsverzeichnis

3.1	Google Benchmark Ausgabe	4
3.2	Beispielausgabe des HANA Profilers	6

Tabellenverzeichnis

Quellcodeverzeichnis

1 Einleitung

2 Grundlagen

2.1 Calculation Engine

2.2 Ausführung von Datenbankabfragen

Datenbankabfragen werden in der Calculation Engine (CE) in drei Schritten ausgeführt. Zuerst wird die Calculation View instanziiert. Anschließend wird dieses mithilfe verschiedener Methoden optimiert. Dieses optimierte Modell wird dann auf der Datenbank ausgeführt.

Wo genau werden die Abfragen ausgeführt?
Was gehört alles zur CalcEngine?

2.3 Verschiedene Arten von Performance Analyse

Benchmarking

Profiling

3 Aktueller Stand der Performance Analyse in der Calculation Engine

Die CE nutzt bereits verschiedene Wege um die Performance und das Verhalten der HANA Datenbank zu analysieren.

3.1 Google Benchmark

Google Benchmark ist ein Open Source Benchmarking Tool von Google, welches es einem ermöglicht einzelne Funktionen in C++ zu benchmarken. Dazu kann man ähnlich zu den meisten Test Frameworks drei verschiedene Codeabschnitte definieren.

Der Hauptabschnitt definiert was genau im Benchmark untersucht werden soll. Diese legt die für die Messung relevante Logik fest.

Der Setup Abschnitt wird einmal vor jeder Ausführung des Benchmarks aufgerufen. In dieser werden die Voraussetzungen für die Ausführung des Hauptabschnitts geschaffen. Man könnte sie beispielsweise nutzen, um Testdaten für den Benchmark zu generieren oder zu laden, da er nicht bei den Messungen beachtet wird.

Der Teardown Abschnitt wird nach jeder Ausführung des Benchmarks aufgerufen. Dieser beeinflusst, wie der Setup Abschnitt, die Messung nicht.

Des Weiteren bietet Google Benchmark die Option, einen Benchmark mehrmals mit unterschiedlichen Parametern durchzuführen. Um beispielsweise die Auswirkung der Größe des Testdatensatzes auf das Ergebnis zu beobachten.

Abbildung 3.1 zeigt eine Beispielhafte Google Benchmark Ausgabe. Benchmark ist dabei der Name des Benchmarks und hinter dem Schrägstrich die Größe des Inputs. Time ist die durchschnittliche Dauer einer Ausführung des Hauptabschnitts über alle Iterationen hinweg. CPU ist die durchschnittliche CPU Zeit einer Ausführung des Hauptabschnitts

über alle Iterationen hinweg. Iterations ist die Anzahl der durchgeführten Iterationen des Hauptabschnitts, bis ein stabiler Durchschnittswert erreicht wurde. (Vgl. Google 2024)

Benchmark	Time	CPU	Iterations
BM_RemoveDetachedNodes/2	4 us	4 us	189823
BM_RemoveDetachedNodes/8	9 us	9 us	78165
BM_RemoveDetachedNodes/64	58 us	58 us	12106
BM_RemoveDetachedNodes/512	469 us	468 us	1515
BM_RemoveDetachedNodes/4096	4237 us	4234 us	166
BM_RemoveDetachedNodes/8192	10026 us	10019 us	60

Abbildung 3.1: Google Benchmark Ausgabe

Google Benchmark wird in der CE meistens genutzt, um das Verhalten der Laufzeit bestimmter Funktionen in künstlich generierten Testfällen zu vergleichen. Hierbei wird jedoch keine HANA Instanz benötigt, da keine Operationen auf einer Datenbank ausgeführt werden. Es werden folglich auch keine Testdatensätze für die Datenbank benötigt, sondern nur Daten, auf welchen man die zu analysierende Methode aufrufen kann. Solche Performance Tests sind also im Vergleich zu Tests, welche auf eine HANA Instanz mit Testdatensätzen zugreifen, relativ einfach. Da sie sich weniger Voraussetzungen haben, und nur auf einen kleinen Teil der Logik fokussiert sind.

3.2 HANA Profiler

Eine weitere Methode die Performance und das Verhalten von Software zu analysieren ist, das bereits in Abschnitt 2.3 beschriebene, Profiling. In der CE wird ein eigener Profiler verwendet. Auf diesen kann entweder manuell oder im Code zugegriffen werden. Dabei sind die wichtigsten Befehle `profiler clear` um die aktuellen Profilinginformationen zurückzusetzen, `profiler start` um den Profiler zu starten, `profiler stop` um den Profiler zu stoppen und `profiler print` um die gesammelten Profilinginformationen auszugeben.

Definition 1. Ein gerichteter Graph ist ein Tupel $G = (V, E)$. V heißt Menge der Knoten. E heißt Menge der gerichteten Kanten. Es gilt $V \neq \emptyset$ und $E \subset V \times V \setminus \{(v, v) | v \in V\}$. Zwischen zwei Knoten $u, v \in V$ gibt es eine Kante mit dem Anfangspunkt u und dem Endpunkt v , wenn $(u, v) \in E$. Ein Pfad P in G ist eine Folge von Knoten v_0, \dots, v_n . Dabei muss $\forall i \in \{0, \dots, n-1\} : (v_i, v_{i+1}) \in E$ gelten. v_0 heißt Anfangspunkt von P , v_n heißt Endpunkt von P und n heißt Länge von P . Ein Pfad heißt geschlossen, wenn $v_0 = v_n$. Ein geschlossener Pfad heißt einfach, wenn $\forall i, j \in \{0, \dots, n-1\}, i \neq j : v_i \neq v_j$ gilt. In einem gerichteten Graphen heißt ein einfach geschlossener Pfad mit $n \geq 2$ auch Zyklus. Ein Graph heißt azyklisch, wenn er keine Zyklen besitzt (Vgl. Knebl 2021, S.221ff). G heißt gewichtet, wenn es eine Abbildung $g : E \rightarrow \mathbb{R}$ gibt, welche jeder Kante ein Gewicht zuordnet. Für $e \in E$ heißt $g(e)$ Gewicht von e (Vgl. Knebl 2021, S.253). Für zwei Knoten c und p gilt, c ist Kindknoten von p , wenn $(p, c) \in E$. Umgekehrt gilt, wenn $(p, c) \in E$, p ist Elternknoten von c . c ist Subknoten von p , wenn $\exists P : (v_0 = p) \wedge (v_n = c)$.

Die Ausgabe erzeugt dabei ist dabei zwei gewichtete gerichtete azyklische Graphen, nach Definition 1, von denen einer die Verteilung der CPU-Zeit und der andere die Verteilung der Wartezeit, der aufgerufenen Funktionen beinhaltet. Im Folgenden werden die beiden Graphen CPU-Graph und Warte-Graph genannt. Abbildung 3.2 stellt eine mögliche Ausgabe des HANA Profilers dar. Die folgende Beschreibung gilt für den CPU- als auch den Warte-Graphen. Jeder Knoten des Graphen spiegelt eine zur Laufzeit des Profilers aufgerufene Funktion wider. Jeder Knoten beinhaltet drei Informationen. Den Namen der aufgerufenen Funktion, sowie den Wert I und den Wert E . I ist der Anteil der Gesamtzeit, welcher von diesem Knoten und all seinen Subknoten benötigt wurde. E ist der Anteil der Gesamtzeit, welcher von diesem Knoten benötigt wurde. Folglich gilt für alle Knoten $I \geq E$. Die Kindknoten eines Knoten K sind die Funktionen, welche von K aufgerufen wurden.




Abbildung 3.2: Beispielausgabe des HANA Profilers

4 Benchmarking-Konzept

4.1 Messung

Um Informationen über die benötigte CPU-Zeit in verschiedenen Schritten der Optimierung herauszufinden, eignet sich der in Abschnitt 3.2 angesprochene Booss-Profiler sehr gut.

4.2 Testdaten

5 Umsetzung

5.1 Implementation der neuen Methode

6 Verifikation

7 Fazit und Ausblick

Literaturverzeichnis

Google (2024). *benchmark A microbenchmark support library*. URL: <https://google.github.io/benchmark/> (Einsichtnahme: 10.06.2024).

Knebl, H. (2021). *Algorithmen und Datenstrukturen : Grundlagen und probabilistische Methoden für den Entwurf und die Analyse / Helmut Knebl*. Springer Vieweg.